

Tarea de Optimización

Frank Piz

November 2025




Figure 1: Gráfico de la superficie de la función objetivo $f(x, y)$.

Aquí está la URL de Github: <https://github.com/Frank100kgbenchpress/Tarea-Evaluativa-Modelos-De-Optim>

1 Análisis Teórico del Modelo

Función Objetivo

$$f(x, y) = 0.1 \left(e^{x^2+y^2} - \tan(1.5 \sin(x+y)) \right)$$

Definimos:

$$r(x, y) = x^2 + y^2, \quad u(x, y) = 1.5 \sin(x+y).$$

Tipo de Variables y Dominio

$x, y \in \mathbb{R}$. $|u(x, y)| \leq 1.5 < \pi/2$, por lo que la función está bien definida y es C^∞ .

Existencia de Solución

$$\lim_{\|(x,y)\| \rightarrow \infty} f(x, y) = +\infty$$

por lo que existe al menos un mínimo global.

Gradiente

$$\nabla f(x, y) = 0.1 \begin{pmatrix} 2x e^r - 1.5 \cos(x + y) \sec^2(u) \\ 2y e^r - 1.5 \cos(x + y) \sec^2(u) \end{pmatrix}$$

Puntos críticos De $\nabla f(x, y) = 0$ se obtiene $x = y$. La ecuación resultante es:

$$2x e^{2x^2} = 1.5 \cos(2x) \sec^2(1.5 \sin(2x)).$$

Hessiana

$$\frac{\partial^2 f}{\partial x^2} = 0.1 \left((2 + 4x^2) e^r - [4.5 \cos^2(x + y) \sec^2(u) \tan(u) - 1.5 \sin(x + y) \sec^2(u)] \right)$$

$$\frac{\partial^2 f}{\partial y^2} = 0.1 \left((2 + 4y^2) e^r - [4.5 \cos^2(x + y) \sec^2(u) \tan(u) - 1.5 \sin(x + y) \sec^2(u)] \right)$$

$$\frac{\partial^2 f}{\partial x \partial y} = 0.1 \left(4xy e^r - [4.5 \cos^2(x + y) \sec^2(u) \tan(u) - 1.5 \sin(x + y) \sec^2(u)] \right)$$

Óptimos Esperados

Hay un mínimo global, numéricamente:

$$(x^*, y^*) \approx (0.776684, 0.776684), \quad f(x^*, y^*) \approx -1.071435.$$

2 Descripción de los Algoritmos Utilizados

La función objetivo que se desea optimizar es:

$$f(x, y) = 0.1 \left(e^{x^2+y^2} - \tan(1.5 \sin(x + y)) \right)$$

Se aplicaron dos métodos numéricos: ****Descenso del Gradiente**** y ****BFGS**** (Quasi-Newton). A continuación se presentan descripciones más detalladas de ambos métodos.

2.1 Método de Descenso del Gradiente

Idea general

El Descenso del Gradiente (Gradient Descent, GD) es uno de los métodos más básicos para minimizar funciones diferenciables. Se basa en la idea geométrica de que el gradiente apunta hacia la dirección de mayor crecimiento de la función, por lo que avanzar en la dirección opuesta reduce su valor.

Fórmula de actualización

Dado un punto (x_k, y_k) , el algoritmo actualiza mediante:

$$(x_{k+1}, y_{k+1}) = (x_k, y_k) - \alpha_k \nabla f(x_k, y_k),$$

donde:

- $\nabla f(x_k, y_k)$ es el vector gradiente,
- $\alpha_k > 0$ es el *tamaño de paso* (learning rate).

Interpretación matemática

El método aproxima la función de manera local con su expansión lineal:

$$f(x_k + p) \approx f(x_k) + \nabla f(x_k)^T p.$$

Para minimizar esta aproximación, se elige:

$$p = -\alpha_k \nabla f(x_k),$$

lo cual justifica la fórmula del algoritmo.

Consideraciones importantes

- Si α es demasiado grande, el algoritmo puede **divergir**.
- Si α es demasiado pequeño, la convergencia es **muy lenta**.
- En funciones con curvatura extrema (como la presente, con el término $e^{x^2+y^2}$), el gradiente puede volverse enorme y provocar saltos incontrolados.




Figure 2: Resultados del método de Descenso del Gradiente.

2.2 Método Quasi-Newton (BFGS)

Idea general

Los métodos de Newton buscan un mínimo resolviendo:

$$\nabla^2 f(x_k) p_k = -\nabla f(x_k),$$

lo que permite tomar pasos que consideran la curvatura real de la función. Sin embargo, calcular la Hessiana exacta es costoso e inestable.

BFGS evita este problema al:

- no calcular la Hessiana real,
- construir una **aproximación** B_k de manera iterativa,
- mantener la matriz simétrica y definida positiva.

Dirección de descenso

$$p_k = -B_k^{-1} \nabla f(x_k)$$

Actualización de la matriz aproximada

$$B_{k+1} = B_k + \frac{y_k y_k^T}{y_k^T s_k} - \frac{B_k s_k s_k^T B_k}{s_k^T B_k s_k},$$

donde:

$$s_k = x_{k+1} - x_k, \quad y_k = \nabla f(x_{k+1}) - \nabla f(x_k).$$




Figure 3: Resultados del método Quasi-Newton (BFGS).

3 Experimentos

Justificación del rango y parámetros utilizados

Para garantizar que los experimentos numéricos fueran estables, reproducibles y sin errores de overflow, fue necesario analizar cuidadosamente los componentes de la función objetivo. En particular, las partes:

$$e^{x^2+y^2} \quad \text{y} \quad \tan(1.5 \sin(x+y))$$

pueden provocar inestabilidades si no se restringen adecuadamente los parámetros iniciales y los algoritmos.

Control del término exponencial

El mayor número representable en `float64` ocurre alrededor de:

$$e^{709} \approx 8 \times 10^{307}.$$

Por este motivo, se impusieron límites estrictos:

$$MAX_EXPONENT = 700, \quad MAX_R2 = 690.$$

Dado que en los experimentos:

$$x_0, y_0 \in [-1, 1],$$

entonces:

$$x^2 + y^2 \leq 2, \quad e^{x^2+y^2} \leq e^2 \approx 7.39.$$

Esto garantiza que la exponencial jamás se acerque a overflow.

Control del término con la tangente

El argumento de la tangente es:

$$1.5 \sin(x+y),$$

con:

$$|1.5 \sin(x+y)| \leq 1.5 < \frac{\pi}{2}.$$

De esta forma, incluso en el peor caso la tangente es finita y moderada, evitando explosiones numéricas en la gradiente y en $\sec^2$.

Elección de los tamaños de paso

Se usaron:

$$\alpha \in \{0.005, 0.01, 0.05\}.$$

Estos valores fueron seleccionados porque:

- controlan la magnitud de los saltos del gradiente,
- evitan salir del rango seguro,
- permiten comparar estabilidad y velocidad entre métodos.

Elección de los números de iteraciones

Se usaron:

$$\{50, 150\} \text{ iteraciones.}$$

Con ello se observó que:

- BFGS converge antes de 15 iteraciones en todos los casos,
- GD necesita muchas iteraciones y aun así no converge bien.

4 Comparación entre BFGS y Descenso del Gradiente

Estadísticas Globales de los Experimentos

Además de analizar los mejores y peores casos, también se calcularon métricas globales que permiten comparar de manera más profunda la estabilidad y eficiencia de cada algoritmo.

Promedio de Iteraciones por Algoritmo

El número promedio de iteraciones requeridas para completar cada experimento fue:

BFGS: 9.728395

Gradiente: 98.611111

Esto confirma que BFGS no solo converge mejor, sino también mucho más rápido: en promedio utiliza **diez veces menos iteraciones** que el Descenso del Gradiente.

Tasa de Éxito por Algoritmo

Definimos “éxito” como converger a un valor:

$$f(x, y) < -1.0,$$

es decir, suficientemente cercano al mínimo global estimado -1.0714 .

Las tasas obtenidas fueron:

Tasa de éxito BFGS: 0.962963

Tasa de éxito GD: 0.176955

Estos valores reflejan una diferencia muy significativa: BFGS converge exitosamente en **el 96%** de los casos, mientras que el método de Gradiente apenas logra un **17%**.

Por qué BFGS es mejor

$$p_k = -B_k^{-1} \nabla f(x_k)$$

BFGS aproxima la Hessiana, lo cual:

- estabiliza la dirección de búsqueda,
- evita oscilaciones,
- requiere menos iteraciones,
- es casi insensible al punto inicial.

$$(x^*, y^*) \approx (0.776684, 0.776684), \quad f(x^*, y^*) \approx -1.071435.$$




Figure 4: Convergencia de BFGS al mínimo global (caso 1).




Figure 5: Convergencia de BFGS al mínimo global (caso 2).

Por qué GD dio los peores valores

$$x_{k+1} = x_k - \alpha \nabla f(x_k)$$

Problemas:

- gradientes enormes por $e^{x^2+y^2}$,

- muy sensible a α ,
- puede caer en mínimos locales,
- direcciones inestables.




Figure 6: GD terminando en zona con $f > 0$.




Figure 7: GD obteniendo $f < 0$ pero lejos del mínimo global.

5 Conclusión

BFGS fue claramente superior: entre los 162 casos exitosos se mostró estable, rápido y consistente. GD de sus 486 casos éxitos produjo resultados muy variables y frecuentemente malos debido a la fuerte curvatura de la función.