

Tarea de Optimización

Frank Piz

November 2025




Figure 1: Gráfico de la superficie de la función objetivo $f(x, y)$.

Aquí está la URL de Github: <https://github.com/Frank100kgbenchpress/Tarea-Evaluativa-Modelos-De-Optim>

1 Análisis Teórico del Modelo

Función Objetivo

$$f(x, y) = 0.1 \left(e^{x^2+y^2} - \tan(1.5 \sin(x+y)) \right)$$

Definimos:

$$r(x, y) = x^2 + y^2, \quad u(x, y) = 1.5 \sin(x+y).$$

Tipo de Variables y Dominio

$x, y \in \mathbb{R}$. $|u(x, y)| \leq 1.5 < \pi/2$, por lo que la función está bien definida y es C^∞ .

Existencia de Solución

$$\lim_{\|(x,y)\| \rightarrow \infty} f(x, y) = +\infty$$

por lo que existe al menos un mínimo global.

Gradiente

$$\nabla f(x, y) = 0.1 \begin{pmatrix} 2x e^r - 1.5 \cos(x + y) \sec^2(u) \\ 2y e^r - 1.5 \cos(x + y) \sec^2(u) \end{pmatrix}$$

Puntos críticos De $\nabla f(x, y) = 0$ se obtiene $x = y$. La ecuación resultante es:

$$2x e^{2x^2} = 1.5 \cos(2x) \sec^2(1.5 \sin(2x)).$$

Hessiana

$$\frac{\partial^2 f}{\partial x^2} = 0.1 \left((2 + 4x^2) e^r - [4.5 \cos^2(x + y) \sec^2(u) \tan(u) - 1.5 \sin(x + y) \sec^2(u)] \right)$$

$$\frac{\partial^2 f}{\partial y^2} = 0.1 \left((2 + 4y^2) e^r - [4.5 \cos^2(x + y) \sec^2(u) \tan(u) - 1.5 \sin(x + y) \sec^2(u)] \right)$$

$$\frac{\partial^2 f}{\partial x \partial y} = 0.1 \left(4xy e^r - [4.5 \cos^2(x + y) \sec^2(u) \tan(u) - 1.5 \sin(x + y) \sec^2(u)] \right)$$

Óptimos Esperados

Hay un mínimo global, numéricamente:

$$(x^*, y^*) \approx (0.776684, 0.776684), \quad f(x^*, y^*) \approx -1.071435.$$

2 Descripción de los Algoritmos Utilizados

La función objetivo que se desea optimizar es:

$$f(x, y) = 0.1 \left(e^{x^2+y^2} - \tan(1.5 \sin(x + y)) \right)$$

Se aplicaron dos métodos numéricos: ****Descenso del Gradiente**** y ****BFGS**** (Quasi-Newton). A continuación se presentan descripciones más detalladas de ambos métodos.

2.1 Método de Descenso del Gradiente

Idea general

El Descenso del Gradiente (Gradient Descent, GD) es uno de los métodos más básicos para minimizar funciones diferenciables. Se basa en la idea geométrica de que el gradiente apunta hacia la dirección de mayor crecimiento de la función, por lo que avanzar en la dirección opuesta reduce su valor.

Fórmula de actualización

Dado un punto (x_k, y_k) , el algoritmo actualiza mediante:

$$(x_{k+1}, y_{k+1}) = (x_k, y_k) - \alpha_k \nabla f(x_k, y_k),$$

donde:

- $\nabla f(x_k, y_k)$ es el vector gradiente,
- $\alpha_k > 0$ es el *tamaño de paso* (learning rate).

Interpretación matemática

El método aproxima la función de manera local con su expansión lineal:

$$f(x_k + p) \approx f(x_k) + \nabla f(x_k)^T p.$$

Para minimizar esta aproximación, se elige:

$$p = -\alpha_k \nabla f(x_k),$$

lo cual justifica la fórmula del algoritmo.

Consideraciones importantes

- Si α es demasiado grande, el algoritmo puede **divergir**.
- Si α es demasiado pequeño, la convergencia es **muy lenta**.
- En funciones con curvatura extrema (como la presente, con el término $e^{x^2+y^2}$), el gradiente puede volverse enorme y provocar saltos incontrolados.

Comportamiento en la función dada

La función presenta:

- regiones muy pronunciadas (por el término exponencial),
- zonas altamente oscilantes (por la tangente),

lo que hace que GD tienda a:

- desviarse hacia regiones donde el gradiente es gigantesco,
- quedar atrapado en mínimos locales,
- obtener resultados muy diferentes dependiendo del punto inicial.




Figure 2: Resultados del método de Descenso del Gradiente.

2.2 Método Quasi-Newton (BFGS)

Idea general

Los métodos de Newton buscan un mínimo resolviendo:

$$\nabla^2 f(x_k) p_k = -\nabla f(x_k),$$

lo que permite tomar pasos que consideran la curvatura real de la función. Sin embargo, calcular la Hessiana exacta es costoso e inestable.

BFGS (Broyden–Fletcher–Goldfarb–Shanno) evita este problema al:

- no calcular la Hessiana real,
- construir una **aproximación** B_k de manera iterativa,
- mantener la matriz simétrica y definida positiva.

Dirección de descenso

$$p_k = -B_k^{-1} \nabla f(x_k)$$

Actualización de la matriz aproximada

$$B_{k+1} = B_k + \frac{y_k y_k^T}{y_k^T s_k} - \frac{B_k s_k s_k^T B_k}{s_k^T B_k s_k},$$

donde:

$$s_k = x_{k+1} - x_k, \quad y_k = \nabla f(x_{k+1}) - \nabla f(x_k).$$

Interpretación matemática

BFGS garantiza que:

B_{k+1} se ajusta a la curvatura detectada entre los puntos x_k y x_{k+1} .

Esto mejora de forma drástica la elección de la dirección descendente.

Ventajas clave

- Convergencia **cuadrática superlineal** en muchos casos.
- Mucho más estable que GD en presencia de curvaturas extremas.
- Muy poco sensible al punto inicial (como se evidenció en los resultados).
- Para problemas de dimensión baja ($n = 2$), el costo computacional es insignificante.

Comportamiento en la función dada

Gracias a que el método ajusta su matriz B_k según la curvatura:

- evita ser arrastrado por el crecimiento explosivo del término $e^{x^2+y^2}$,
- evita oscilaciones creadas por la tangente,
- converge de manera consistente al mínimo global alrededor de:

$$(x^*, y^*) \approx (0.776684, 0.776684), \quad f(x^*, y^*) \approx -1.071435.$$




Figure 3: Resultados del método Quasi-Newton (BFGS).

3 Tablas de Resultados

3.1 Top 15 mejores resultados (todos BFGS)

x	y	$f(x, y)$	algoritmo
0.776684	0.776684	-1.071435	bfgs
0.776684	0.776684	-1.071435	bfgs
0.776684	0.776684	-1.071435	bfgs
0.776684	0.776684	-1.071435	bfgs
0.776684	0.776684	-1.071435	bfgs
0.776684	0.776684	-1.071435	bfgs
0.776684	0.776684	-1.071435	bfgs
0.776684	0.776684	-1.071435	bfgs
0.776684	0.776684	-1.071435	bfgs
0.776684	0.776684	-1.071435	bfgs
0.776684	0.776684	-1.071435	bfgs
0.776684	0.776684	-1.071435	bfgs
0.776684	0.776684	-1.071435	bfgs
0.776684	0.776684	-1.071435	bfgs
0.776684	0.776684	-1.071435	bfgs
0.776684	0.776684	-1.071435	bfgs

3.2 Peores 10 resultados (GD)

x	y	$f(x, y)$	algoritmo
-1.00	-0.75	1.215443	gradiente
-0.75	-1.00	1.215443	gradiente
-1.00	-0.75	1.218051	gradiente
-0.75	-1.00	1.218051	gradiente
-1.00	-1.00	1.218833	gradiente
-1.00	-1.00	1.218833	gradiente
-1.00	-1.00	1.218833	gradiente
-1.00	-1.00	1.218833	gradiente
-1.00	-1.00	1.218833	gradiente
-1.00	-1.00	1.218833	gradiente

4 Comparación entre BFGS y Descenso del Gradiente

1. Por qué BFGS es mejor

$$p_k = -B_k^{-1} \nabla f(x_k)$$

BFGS aproxima la Hessiana, lo cual:

- estabiliza la dirección de búsqueda,
- evita oscilaciones,
- requiere menos iteraciones,
- es casi insensible al punto inicial.

$$(x^*, y^*) \approx (0.776684, 0.776684), \quad f(x^*, y^*) \approx -1.071435.$$




Figure 4: Convergencia de BFGS al mínimo global (caso 1).




Figure 5: Convergencia de BFGS al mínimo global (caso 2).

2. Por qué GD dio los peores valores

$$x_{k+1} = x_k - \alpha \nabla f(x_k)$$

Problemas:

- gradientes enormes por $e^{x^2+y^2}$,
- muy sensible a α ,
- puede caer en mínimos locales,
- direcciones inestables.




Figure 6: GD terminando en zona con $f > 0$.




Figure 7: GD obteniendo $f < 0$ pero lejos del mínimo global.

5 Conclusión

BFGS fue claramente superior: estable, rápido y consistente. GD produjo resultados muy variables y frecuentemente malos debido a la fuerte curvatura de la función.