

# Tarea de Optimización

Frank Piz

November 2025

## 1 Análisis Teórico del Modelo

### Función Objetivo

$$f(x, y) = 0.1 \left( e^{(x^2+y^2)} - \tan(1.5 \sin(x+y)) \right)$$

Definimos para simplificar:

$$r(x, y) := x^2 + y^2, \quad u(x, y) := 1.5 \sin(x+y).$$

### 1. Tipo de Variables y Dominio

Las variables  $x$  y  $y$  son **continuas reales**,  $x, y \in \mathbb{R}$ .

El argumento de la tangente  $u(x, y)$  está acotado en  $[-1.5, 1.5]$ . Como  $|1.5| < \pi/2 \approx 1.5708$ , la tangente nunca se indetermina. Por tanto, la función  $f$  está bien definida y es **suave e infinitamente diferenciable** ( $C^\infty$ ) en todo  $\mathbb{R}^2$ .

### 2. Existencia de Solución y de Óptimo Global

El término  $e^{x^2+y^2}$  domina para valores grandes. Dado que  $f$  es continua y  $\lim_{\|(x,y)\| \rightarrow \infty} f(x, y) = +\infty$  (coercitividad), se garantiza la existencia de **al menos un mínimo global** (Teorema de Weierstrass, extendido a funciones coercitivas en  $\mathbb{R}^n$ ). No existen máximos globales.

### 3. Gradiente ( $\nabla f$ ) y Puntos Críticos

**Gradiente (Condición Necesaria de Primer Orden)**

$$\nabla f(x, y) = 0.1 \begin{pmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{pmatrix} = 0.1 \begin{pmatrix} 2x e^r - 1.5 \cos(x+y) \sec^2(u) \\ 2y e^r - 1.5 \cos(x+y) \sec^2(u) \end{pmatrix}.$$

**Deducción de Puntos Críticos** Para que  $(x^*, y^*)$  sea un punto crítico,  $\nabla f(x^*, y^*) = \mathbf{0}$ , lo que implica igualar a cero ambas componentes:

$$\frac{\partial f}{\partial x} = 0 \quad \text{y} \quad \frac{\partial f}{\partial y} = 0.$$

Restando las dos ecuaciones, se obtiene:

$$0.1 \left( 2x^* e^{r^*} - 1.5 \cos(\dots) \right) = 0.1 \left( 2y^* e^{r^*} - 1.5 \cos(\dots) \right)$$

Esto se simplifica a  $2x^* e^{r^*} = 2y^* e^{r^*}$ , lo cual implica que  $x^* = y^*$  (dado que  $e^{r^*} > 0$ ). La condición unidimensional para los puntos críticos es:

$$2x e^{2x^2} = 1.5 \cos(2x) \sec^2(1.5 \sin(2x)).$$

#### 4. Matriz Hessiana ( $H_f$ ) y Test de Segundo Orden

**Hessiana** La matriz Hessiana  $H_f$  es simétrica por el Teorema de Clairaut (dado que  $f$  es  $C^\infty$ ):

$$\frac{\partial^2 f}{\partial x \partial y} = \frac{\partial^2 f}{\partial y \partial x}.$$

Las componentes no idénticas son:

$$\frac{\partial^2 f}{\partial x^2} = 0.1 \left( (2 + 4x^2)e^r - [4.5 \cos^2(x + y) \sec^2(u) \tan(u) - 1.5 \sin(x + y) \sec^2(u)] \right),$$

$$\frac{\partial^2 f}{\partial y^2} = 0.1 \left( (2 + 4y^2)e^r - [4.5 \cos^2(x + y) \sec^2(u) \tan(u) - 1.5 \sin(x + y) \sec^2(u)] \right),$$

$$\frac{\partial^2 f}{\partial x \partial y} = 0.1 \left( 4xy e^r - [4.5 \cos^2(x + y) \sec^2(u) \tan(u) - 1.5 \sin(x + y) \sec^2(u)] \right).$$

**Condiciones Suficientes de Segundo Orden** En un punto crítico  $(x^*, y^*)$  donde  $\nabla f(x^*, y^*) = \mathbf{0}$ :

- Si  $H_f$  es **definida positiva**  $\Rightarrow$  mínimo local estricto.
- Si  $H_f$  es **indefinida**  $\Rightarrow$  punto de silla.

#### 5. Conclusiones sobre Óptimos y Región de Prueba

**Comportamiento General** La función es no convexa. La **coercitividad** garantiza la existencia de un mínimo global. La simetría y la naturaleza oscilante implican que los puntos críticos se encuentran en la recta  $x = y$  y que es probable que existan **múltiples mínimos locales** cerca del origen.

**Análisis en la Región**  $[-100, 100]^2$  En este dominio, el término exponencial  $e^{x^2+y^2}$  domina rápidamente fuera de una pequeña región alrededor del origen (por ejemplo,  $|x|, |y| < 2$ ). Esto implica:

- Los **mínimos** (locales y globales) se ubican en el **interior** de esta región, cerca de  $(0, 0)$ .
- El resto de la región presenta un crecimiento monótono hacia  $+\infty$ .

El problema de optimización se reduce a una búsqueda local eficiente a lo largo de la diagonal  $x = y$  cerca del origen.

## 2 Descripción de los Algoritmos Utilizados

En esta sección se describen los dos métodos de optimización aplicados a la función

$$f(x, y) = 0.1(e^{x^2+y^2} - \tan(1.5 \sin(x+y))),$$

dentro del dominio de prueba  $[-100, 100] \times [-100, 100]$ . Ambos algoritmos buscan minimizar  $f(x, y)$ , aprovechando su suavidad y la existencia de gradiente e información de curvatura.

### 4.1. Método de Descenso del Gradiente

**Descripción general** El método de **descenso del gradiente** es un algoritmo iterativo de optimización que actualiza las variables en la dirección opuesta al gradiente, buscando la región de menor valor de la función. En cada iteración:

$$(x_{k+1}, y_{k+1}) = (x_k, y_k) - \alpha_k \nabla f(x_k, y_k),$$

donde  $\alpha_k > 0$  es la **tasa de aprendizaje** o **tamaño de paso**.

**Criterio de parada** El algoritmo se detiene cuando se cumple alguna de las siguientes condiciones:

- $\|\nabla f(x_k, y_k)\| < \varepsilon$  (el gradiente es casi nulo),
- el número máximo de iteraciones es alcanzado,
- o los cambios en  $f(x, y)$  entre iteraciones son despreciables.

**Uso en la función dada** Para la función  $f(x, y)$ , el gradiente es continuo y fácilmente computable:

$$\nabla f(x, y) = 0.1 \begin{pmatrix} 2xe^{x^2+y^2} - 1.5 \cos(x+y) \sec^2(1.5 \sin(x+y)) \\ 2ye^{x^2+y^2} - 1.5 \cos(x+y) \sec^2(1.5 \sin(x+y)) \end{pmatrix}.$$

En la práctica:

- Se elegirá un punto inicial  $(x_0, y_0)$  dentro de  $[-2, 2]$ , pues fuera de esa zona la función crece rápidamente.

- El tamaño de paso  $\alpha_k$  puede ser fijo (por ejemplo,  $10^{-3}$ ) o adaptativo mediante búsqueda en línea (*line search*) tipo Armijo.
- Se espera convergencia hacia el mínimo global cercano al origen.
- Sin embargo, debido al término oscilante  $-\tan(1.5 \sin(x+y))$ , el método puede estancarse en mínimos locales si el punto inicial no está suficientemente cerca del mínimo global.

### Ventajas y desventajas

- Ventajas: fácil de implementar, requiere solo el gradiente, bajo costo computacional por iteración.
- Desventajas: puede converger lentamente o quedar atrapado en mínimos locales; sensible al tamaño de paso.

## 4.2. Método Quasi-Newton (BFGS)

**Descripción general** El método **Quasi-Newton** (en particular el algoritmo BFGS) mejora el descenso del gradiente aproximando la información de la Hessiana sin calcularla explícitamente. La dirección de búsqueda  $p_k$  se obtiene como:

$$p_k = -B_k^{-1} \nabla f(x_k, y_k),$$

donde  $B_k$  es una matriz que aproxima la Hessiana  $H_f(x_k, y_k)$ . La actualización de  $B_k$  se realiza mediante:

$$B_{k+1} = B_k + \frac{y_k y_k^T}{y_k^T s_k} - \frac{B_k s_k s_k^T B_k}{s_k^T B_k s_k},$$

con

$$s_k = x_{k+1} - x_k, \quad y_k = \nabla f(x_{k+1}) - \nabla f(x_k).$$

**Uso en la función dada** Para  $f(x, y)$ :

- El gradiente  $\nabla f(x, y)$  se utiliza directamente en cada iteración.
- No se requiere calcular la Hessiana exacta, lo que reduce el costo computacional frente al método de Newton puro.
- La función es suave y coercitiva, por lo que BFGS converge localmente de manera superlineal cerca de los mínimos.
- Debido a su actualización adaptativa de curvatura, puede escapar más fácilmente de mínimos locales débiles que el descenso del gradiente.

**Criterio de parada** Mismos criterios que en el descenso del gradiente:

$$\|\nabla f(x_k, y_k)\| < \varepsilon, \quad \text{o bien un número máximo de iteraciones.}$$

### Ventajas y desventajas

- Ventajas: converge más rápido que el descenso del gradiente, no requiere Hessiana exacta, robusto ante curvaturas pronunciadas.
- Desventajas: mayor costo por iteración, necesita almacenamiento y operaciones matriciales (aunque en este caso  $n = 2$ ).

### 4.3. Comparación esperada entre ambos métodos

- El **descenso del gradiente** alcanzará el mínimo global si parte cerca del origen, pero puede requerir muchos pasos para valores de  $\alpha$  pequeños.
- El **método Quasi-Newton (BFGS)** convergerá en menos iteraciones gracias a su aproximación de la curvatura local.
- En la región  $[-100, 100]^2$ , ambos métodos deben detenerse antes de alcanzar los bordes, pues  $f(x, y)$  crece rápidamente y no hay óptimos fuera del entorno del origen.

**Conclusión general** Ambos algoritmos son adecuados para el problema:

- **Descenso del Gradiente:** simple, estable, pero más lento.
- **Quasi-Newton (BFGS):** más eficiente, aprovecha información de curvatura y tiende a converger más rápido hacia el mínimo global de  $f$ .